

基于稳健 Hausdorff 距离与多特征融合的 音乐旋律线几何建模

——从三维曲线相似性到可信曲风区分

摘 要

本文研究如何将多声部钢琴 MIDI 转化为可比较的三维旋律曲线，如何用 Hausdorff 距离度量曲线几何相似性，以及这种几何信息对音乐曲风区分究竟具有多大作用。围绕表示、度量和验证三个环节，本文建立了一套可复现且主动防范数据泄漏的建模流程。

针对旋律表示问题，本文从按键事件中提取同一时刻的最高音作为主旋律 (skyline)，以归一化时间相位、相对中位音高和加权力度构造三维旋律线。为控制同曲不同版本造成的重复，通过曲名、文件哈希和旋律指纹三种方式识别重复作品。在 5317 个候选文件中识别并排除 75 个跨曲风冲突组，最终从 Classical、Jazz、Rock、Blues、Electronic 五类各抽取 100 首，共 500 首独立作品。

针对距离稳健性问题，本文比较 max-Hausdorff、95% 分位 Hausdorff 与 Modified Hausdorff Distance (MHD)，并将重采样点数、力度权重和近邻数置于重复内层交叉验证中联合选择。单点扰动实验表明，max-Hausdorff 会被局部异常迅速主导，而 MHD 仅缓慢变化。真实数据中同类与异类 MHD 均值分别为 0.3196 和 0.3487，均值差为 0.0292；9999 次置换检验得到 $p = 0.0001$ ，但配对 AUC 仅为 0.5645，说明差异在统计上显著，但分布重叠较大。

针对曲风区分问题，本文在统一的嵌套分组五折框架下设置相位对齐轨迹 RMSE、多变量 DTW、逻辑回归和随机森林等对照，并建立 MHD-随机森林概率融合。主要几何模型多参数 MHD 的折外准确率为 40.80% (95% CI: 36.80%-45.00%)；随机森林达到 55.60% (51.20%-60.00%)；融合模型为 54.00% (49.80%-58.20%)。五组外层随机种子下三者平均准确率分别为 41.12%、56.24% 和 55.08%。融合未显著优于随机森林 (Holm 校正 $p = 0.3222$)，表明几何距离与描述符虽存在局部互补，但不足以稳定转化为额外分类收益。

综上，稳健 Hausdorff 距离能够提供可解释、可检验的旋律几何相似性，并具有明显高于随机水平的曲风信息；但其单独判别能力有限。对本题而言，Hausdorff 更适合作为解释旋律形状的几何模型和多特征系统的辅助证据，而非独立的高精度曲风分类器。

关键词：旋律线；Modified Hausdorff；MIDI；数据泄漏；嵌套分组交叉验证；曲风分类；模型融合

1 问题描述与总体思路

题目要求将一段音乐抽象为离散音符序列，每个音符包含时间、音高和音量信息；将相邻音符视为三维空间中的点并连接为旋律曲线；在此基础上研究 Hausdorff 距离能否量化不同旋律线之间的几何相似性，并讨论这种度量对区分音乐曲风是否有效。

这一任务涉及三个环节。**首先是旋律表示：**多声部 MIDI 同一时刻可能包含多个音符，不同作品的时长、速度、调性和力度范围也不同，需要统一的旋律表示。**其次是距离度量：**标准 Hausdorff 距离由最坏匹配点决定，可能过度响应装饰音或解析误差，需要更稳健的变体。**最后是结果验证：**曲风标签与作品版本并非独立，如果同一作品的不同版本分别进入训练集和测试集，所得精度会严重偏高。图 1 概括了本文的完整方法链和处理流程。

v3 建模方法谱系




图 1：本文从旋律表示、距离模型、分类融合到可信评价的方法谱系

2 数据预处理

2.1 MIDI 文件格式与旋律提取

MIDI 文件存储的是演奏指令而非音频波形。其核心事件为按键事件（Note On），携带三个信息：按键时刻 τ 、音高 p （0-127，每差 1 为一个半音）和力度 v （0-127，越重越响）。

同一时刻可能出现多个音符（即和弦），本文采用 skyline 方法提取主旋律：对每个起始时刻 τ ，若同时出现多个音符，则先选音高最高者；若最高音并列，再保留力度较大的音符：

$$(p_\tau, v_\tau) = \arg \max_{(p,v) \in C_\tau} (p, v), \quad (1)$$

其中 C_τ 表示时刻 τ 的同时发声音符集合。少于 32 个起音的文件被视为信息不足并排除。

不同歌曲的音符数量差异很大（从几十到上千），因此需要对时间轴做归一化和重采样。设首末音时刻为 $\tau_{\min}$ 与 $\tau_{\max}$ ，定义时间相位：

$$t_i = \frac{\tau_i - \tau_{\min}}{\tau_{\max} - \tau_{\min}} \in [0, 1]. \quad (2)$$

在 $[0, 1]$ 上均匀取 N 个点，对音高和力度做分段线性插值——即原来没有采样点的位置，根据相邻两个原始点按比例计算插值。该设计不同于三维弧长重采样：弧长会被音高和力度尺度共同影响，使采样位置和距离权重耦合；时间均匀采样则将二者分离，便于解释敏感性结果。




图 2: 五类曲风的标准化三维旋律线示例

三维旋律点的构造方式为：音高减去中位数（实现移调不变性），力度以 64 为中心缩放并赋予可调权重：

$$\mathbf{x}_i(w_v) = \left(t_i, \frac{p_i - \text{median}(p)}{12}, w_v \frac{v_i - 64}{32} \right) \in \mathbb{R}^3. \quad (3)$$

其中 w_v 的候选值为 $\{0, 0.1, 0.25, 0.5\}$ ， $w_v = 0$ 对应忽略力度。

2.2 数据去重与样本选择

ADL Piano MIDI 数据集包含 Classical、Jazz、Rock、Blues 和 Electronic 五类，共 5317 个 MIDI 文件。由于同一首曲子可能以不同文件名的版本出现（如不同编曲、不同音源），直接使用会导致训练集和测试集之间出现数据泄漏，虚高分类精度。

本文采用三种方式联合识别重复：**一是规范化曲名**（去除 live、remaster 等版本后缀）；**二是 SHA-256 文件哈希**（两个文件内容完全相同时哈希值相同）；**三是旋律指纹**——将 skyline 提取后对时间归一化、音高去移调，再计算哈希。三种方式只要有一种成立，就视为同一重复组；若一个组跨越多个曲风，则整组排除。数据中共识别 75 个跨曲风冲突组，涉及 187 个文件。




图 3: 原始文件、去重后独立组与最终平衡样本的数据筛选漏斗

如图 3 所示，去重后以样本容量最受约束的曲风为准。程序以随机种子 2026 打乱各类候选组，最终五类各取 100 首，共 500 首独立作品，五类均衡。若任一曲风不足 100 个可用组，代码自动退回五类共同可用上限。

2.3 符号说明

表 1: 主要符号及含义

符号	含义	符号	含义
M	一首作品的旋律线点集	$h(A, B)$	从 A 到 B 的有向 Hausdorff 距离
τ_i, p_i, v_i	第 i 个音符的时间、音高和力度	$H(A, B)$	双向 max-Hausdorff 距离
$\mathbf{x}_i$	标准化后的三维旋律点	$H_{0.95}(A, B)$	95% 分位 Hausdorff 距离
$H_{\text{MHD}}(A, B)$	改进 Hausdorff 距离	N	旋律曲线的均匀重采样点数
w_v	力度维权重	K	近邻分类的邻居数
α	融合中随机森林概率权重	—	—

3 模型方法

3.1 Hausdorff 距离及其变体

对两条旋律线点集 $A = \{\mathbf{a}_i\}_{i=1}^m$ 与 $B = \{\mathbf{b}_j\}_{j=1}^n$, 有向 Hausdorff 距离定义为

$$h(A, B) = \max_{\mathbf{a} \in A} \min_{\mathbf{b} \in B} \|\mathbf{a} - \mathbf{b}\|_2, \quad (4)$$

即 A 的每个点找 B 里最近的点, 取这些最近距离的最大值。双向距离为两个方向的最大值:

$$H(A, B) = \max\{h(A, B), h(B, A)\}. \quad (5)$$

本文使用 KD-tree 搜索最近点, 使单次有向匹配由 $O(mn)$ 降为 $O(m \log n)$ 。

上述 max-Hausdorff 的一个问题是: 一个离群点就能主导整个距离。为此引入两种更稳健的变体:

95% 分位 Hausdorff 距离 (Q95-HD): 将有向最近距离集合的最大值替换为 95% 分位数:

$$H_{0.95}(A, B) = \max \left\{ Q_{0.95} \left(\min_{\mathbf{b} \in B} \|\mathbf{a} - \mathbf{b}\|_2 \right), Q_{0.95} \left(\min_{\mathbf{a} \in A} \|\mathbf{b} - \mathbf{a}\|_2 \right) \right\}. \quad (6)$$

改进 Hausdorff 距离 (MHD) [2]: 将最大值替换为平均值:

$$h_{\text{MHD}}(A, B) = \frac{1}{|A|} \sum_{\mathbf{a} \in A} \min_{\mathbf{b} \in B} \|\mathbf{a} - \mathbf{b}\|_2, \quad (7)$$

$$H_{\text{MHD}}(A, B) = \max\{h_{\text{MHD}}(A, B), h_{\text{MHD}}(B, A)\}. \quad (8)$$

外层仍保留双向最大值, 避免较短或较密的曲线在单向匹配中被完全覆盖。

此外, 为分析顺序信息的作用, 本文还设置了两个对照模型:

相位对齐 RMSE: 两曲线采样网格相同时, 按相同相位逐点计算欧氏差的均方根。该模型严格保持顺序, 但不允许时间变形, 作为零时间扭曲基线。

多变量 DTW [3]: 设两条音高-力度序列为 $P = (\mathbf{p}_1, \dots, \mathbf{p}_m)$ 和 $Q = (\mathbf{q}_1, \dots, \mathbf{q}_n)$, 动态规划递推为

$$D(i, j) = \|\mathbf{p}_i - \mathbf{q}_j\|_2 + \min\{D(i-1, j), D(i, j-1), D(i-1, j-1)\}. \quad (9)$$

DTW 使用 Sakoe-Chiba 窗口限制对齐范围, 在内层联合选择 N 、 w_v 、窗口比例和 K 。

3.2 描述符特征与分类模型

距离矩阵采用 K-NN 分类。对测试样本 x , 在训练集中选择距离最小的 K 个邻居, 以类别票数比例作为几何模型概率。

为判别 Hausdorff 距离之外的曲风信息, 本文同时提取 55 个可解释描述符, 分为尺度与长度、音高统计、音程与轮廓、力度动态、节奏、音级与调性六组。描述符只由单首作品计算, 不使用全数据标签或测试折统计量。

描述符侧设置两种对照：**多项逻辑回归**用于检验线性可分信息；**随机森林** [7] 用于捕捉非线性关系（500 棵树、类别平衡权重）。此外定义概率融合模型检验两者是否互补：

$$\mathbf{p}_{\text{fusion}}(x) = \alpha \mathbf{p}_{\text{RF}}(x) + (1 - \alpha) \mathbf{p}_{\text{MHD}}(x), \quad (10)$$

其中 $\alpha \in \{0.25, 0.5, 0.75\}$ 。

3.3 实验设计

嵌套分组交叉验证。外层采用分层分组五折，保证相同重复组只出现在一个折中。所有可调模型均在外层训练集内部执行 3 个随机种子下的三折分组交叉验证，以平均平衡准确率选择参数（ N 、 w_v 、 K 、 α ）。外层测试折不参与任何参数选择 [9, 10]。主结果由随机种子 42 的五个外层折外预测合并得到；另以 11、23、42、67、101 五组种子重复完整流程，评价排序稳定性。

统计检验。对合并后的折外预测，在每个曲风内部有放回抽样 2000 次 [11]，取 2.5% 和 97.5% 分位数作为 95% 置信区间。针对主要模型使用配对检验 [12] 和 Holm 校正 [13] 进行差异显著性判断。

距离分布检验。将所有两两 MHD 分为同曲风和异曲风。由于同一作品参与多个配对，以作品组为单位随机打乱曲风标签 9999 次：

$$\Delta = \bar{d}_{\text{between}} - \bar{d}_{\text{within}}, \quad (11)$$

并计算 p 值。同时报告配对 AUC——随机抽取一对同类和一对异类时，同类距离更小的概率。

4 结果分析

4.1 Hausdorff 距离的稳健性检验

在合成正弦旋律上只扰动一个采样点，逐步增大音高偏移。图 4 表明 max-HD 随异常幅度近似线性上升，Q95-HD 几乎不受影响，MHD 仅缓慢增加。这说明均值型聚合确实比最大值型距离更稳定。




图 4: 单点离群扰动下三种 Hausdorff 距离的响应

4.2 同类与异类距离分析

固定 $N = 96, w_v = 0.25$ 时，同曲风 MHD 均值为 0.3196，异曲风均值为 0.3487，差值为 0.0292。打乱检验得到 $p = 0.0001$ ，说明曲风标签与距离结构并非完全无关。然而配对 AUC 仅为 0.5645，图 5 中两分布仍大量重叠。




图 5: 同曲风与异曲风旋律的 MHD 分布及效应量

图 6 显示不同曲风存在局部结构，但五类分布并未形成清晰分离的簇。该结果与




图 6: MHD 空间中的曲风关系与整体重叠

AUC 一致：Hausdorff 空间包含弱曲风信息，却不具备直接线性分离结构。

4.3 分类模型对比

表 2: 统一嵌套分组验证下的模型表现

方法	折外准确率 (95% CI)	宏平均 F1	模型角色
HD, 逐曲 Min-Max	31.20% (27.60–35.00)	0.291	原始基线
HD, 相对音高 TPV	34.40% (30.80–38.40)	0.331	三维最大值
95% 分位 HD	34.40% (30.60–38.40)	0.333	稳健分位数
固定 MHD	38.40% (34.40–42.60)	0.373	整体均值
相位对齐轨迹 RMSE	23.60% (20.40–27.00)	0.196	严格顺序基线
多参数 MHD (嵌套)	40.80% (36.80–45.00)	0.398	主要几何模型
多变量 DTW (嵌套)	35.20% (31.20–39.00)	0.344	局部时序对齐
多项逻辑回归	52.20% (48.00–56.60)	0.521	线性描述符
随机森林描述符	55.60% (51.20–60.00)	0.557	非线性能力对照
MHD-RF 概率融合	54.00% (49.80–58.20)	0.537	联合模型
随机猜测	20.00%	0.200	五类均衡

注：区间为 2000 次分层自助法的 95% CI；所有数值均来自相同的外层折外预测。

表 2 和图 7 显示：固定 MHD 比三维 max-HD 高 4.0 个百分点；嵌套多参数 MHD 达到 40.80%，五个外层折中四次选择 $N = 48$ ，且五次均选择 $w_v = 0.5$ ，表明力度信息有用，而过密采样可能放大局部装饰差异。多变量 DTW 为 35.20%，低于 MHD，说明点集整体形状在本数据中比局部时间对齐更有效。随机森林达到 55.60%，明显高于纯




图 7: 距离模型、描述符模型与概率融合的折外准确率及 95% 置信区间

几何模型。

4.4 混淆矩阵与融合分析




图 8: 多参数 MHD、随机森林和概率融合的归一化折外混淆矩阵

图 8 显示多参数 MHD 对 Classical 和 Jazz 的识别相对较好，而 Rock、Blues 和 Electronic 之间存在明显混淆。随机森林提高了五类整体召回率。融合模型在内层均选择 $\alpha = 0.75$ （更依赖随机森林），准确率为 54.00%，低于随机森林的 55.60%。配对检验表明随机森林显著优于多参数 MHD ($p < 0.0001$)，但随机森林与融合差异不显著 ($p = 0.3222$)。

图 9 进一步解释了这一结果：MHD 能独立纠正一部分随机森林错误，随机森林也能纠正更多 MHD 错误，但融合在两者均错误的样本上改善有限。因此本研究不将融合模型宣称为性能提升，而是视为一次有控制的负结果——几何相似性具有补充解释价值，

表 3: 三类主要模型的分曲风折外召回率 (%)

模型	Classical	Jazz	Rock	Blues	Electronic
多参数 MHD	56.00	54.00	23.00	46.00	25.00
随机森林	79.00	58.00	40.00	51.00	50.00
概率融合	77.00	55.00	41.00	49.00	48.00




图 9: 几何模型与描述符模型的正确性分歧及融合模型表现

但简单线性概率融合不足以稳定利用这种互补。

4.5 特征分析与参数敏感性

随机森林的特征重要性使用每个外层测试折上的置换重要性衡量。消融实验每次删除一个特征组并重新执行验证。




图 10: 描述符模型的预测关联与组级信息贡献

移除节奏组时平衡准确率下降 4.8 个百分点，影响最大；移除力度动态、音级调性和音程轮廓时分别下降 2.2、1.8 和 1.2 个百分点。这说明随机森林的优势主要来自节奏、

动态和调性信息的联合表达。




图 11: 固定 MHD 对重采样点数和力度权重的敏感性

图 11 表明 MHD 的性能不随重采样点数单调增加。48 点通常优于 96 点，说明过密采样会增加局部装饰的影响。另一方面，力度权重从 0 增加到 0.5 时性能上升，证明力度是有效维度。

五组外层随机种子下,多参数 MHD、随机森林和融合的平均准确率分别为 $41.12\% \pm 1.45\%$ 、 $56.24\% \pm 1.24\%$ 和 $55.08\% \pm 1.06\%$ 。三类模型排序一致: 随机森林最高, 融合次之, MHD 最低, 说明主结论不是某一次分折造成的。




图 12: 五组外层随机种子下三类主要模型的稳定性

5 结论

5.1 主要结论

研究表明，同曲风旋律的 MHD 在总体上小于异曲风旋律，9999 次打乱检验得到 $p = 0.0001$ ，但配对 AUC 仅为 0.5645，说明有统计证据但效应不大。MHD 的准确率达到 40.80%，验证了均值聚合和力度权重的有效性。随机森林达到 55.60%，显著优于几何模型；节奏特征消融造成最大性能下降，说明曲风信息更多分布在节奏、力度和音级特征中。MHD-RF 融合为 54.00%，与随机森林差异不显著。

因此，对题目所问“Hausdorff 距离在区分音乐曲风方面是否有效”，本文的回答是：**有效，但有限**。它能够揭示旋律形状的群体差异，为多特征系统提供独立视角；但要想获得更可靠的曲风识别，仍需结合节奏、力度、和声等其他信息。

5.2 讨论与改进方向

数据方面。本文只使用 ADL 钢琴 MIDI，钢琴化控制了音色变量，但真实曲风识别中的配器、音色、和声织体被有意舍弃。Rock、Electronic 等宽标签内部异质性也限制了可达到精度。

方法方面。Skyline 只是主旋律的启发式近似，伴奏高音可能被误选。Hausdorff 距离不保持顺序，虽然 DTW 提供了时序对照，但未进行乐句级局部匹配。去重使用的旋律指纹为防泄漏而忽略速度和移调，可能将相近改编保守地归为同组。

后续改进。可使用声部跟踪替代最高音规则，将整曲划分为短乐句后执行局部 MHD 或 DTW。融合模型可在严格嵌套框架下尝试更灵活的组合方式。若目标转向真实曲风分类，还应加入和弦、调式、音色等特征，并在独立语料上进行外部验证。

参考文献

- [1] Hausdorff F. *Grundzüge der Mengenlehre*. Leipzig: Veit, 1914.
- [2] Dubuisson M P, Jain A K. A modified Hausdorff distance for object matching[C]. Proceedings of the 12th International Conference on Pattern Recognition, 1994: 566–568.
- [3] Sakoe H, Chiba S. Dynamic programming algorithm optimization for spoken word recognition[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1978, 26(1): 43–49.
- [4] Müller M. *Information Retrieval for Music and Motion*. Berlin: Springer, 2007.
- [5] Ferreira L N, Lelis L H S, Whitehead J. Computer-generated music for tabletop role-playing games[C]. Proceedings of the 16th AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, 2020.
- [6] Cover T M, Hart P E. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21–27.

- [7] Breiman L. Random forests[J]. Machine Learning, 2001, 45: 5–32.
- [8] Tzanetakis G, Cook P. Musical genre classification of audio signals[J]. IEEE Transactions on Speech and Audio Processing, 2002, 10(5): 293–302.
- [9] Varma S, Simon R. Bias in error estimation when using cross-validation for model selection[J]. BMC Bioinformatics, 2006, 7: 91.
- [10] Cawley G C, Talbot N L C. On over-fitting in model selection and subsequent selection bias in performance evaluation[J]. Journal of Machine Learning Research, 2010, 11: 2079–2107.
- [11] Efron B, Tibshirani R J. *An Introduction to the Bootstrap*. New York: Chapman and Hall, 1993.
- [12] McNemar Q. Note on the sampling error of the difference between correlated proportions or percentages[J]. Psychometrika, 1947, 12(2): 153–157.
- [13] Holm S. A simple sequentially rejective multiple test procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70.

A 复现实验说明

最终实验入口和依赖清单分别为：

```
code/final_experiment.py
requirements.txt
```

在项目根目录执行：

```
python code/final_experiment.py --per-genre 100 --points 96
python code/paper_assets.py
latexmk -xelatex -interaction=nonstopmode \
    -halt-on-error -cd report_clk/main.tex
```

B 支撑材料文件列表

表 4: 主要支撑材料及用途

文件或目录	用途
code/data_pipeline.py	三重指纹、并集分组、平衡抽样和数据审计
code/distance_models.py	Hausdorff 距离族、轨迹 RMSE、多变量 DTW 和缓存
code/evaluation.py	嵌套分组验证、自助法、配对检验、融合与消融
code/final_experiment.py	完整实验编排
code/paper_assets.py	中文论文图表生成
code/test_pipeline.py	MIDI、指纹、距离、分组隔离和端到端回归测试

C 主要算法伪代码

Listing 1: 防泄漏分组与嵌套概率融合

```
index every MIDI:
    title_id = canonical_title(file)
    byte_id = sha256(file)
    melody_id = hash(normalized_skyline(file))
union files sharing any identifier
exclude every connected component spanning multiple genres
sample one parseable version from each remaining component

for outer_train, outer_test in grouped_stratified_5fold:
    for inner split generated only from outer_train:
        fit RF descriptors on inner_train
        for N, velocity_weight, K, rf_weight:
            P_mhd = KNN_probability(distance[N, velocity_weight], K)
            P_mix = rf_weight * P_rf + (1-rf_weight) * P_mhd
            score candidate on inner_validation
        choose candidate with highest mean inner balanced accuracy
        refit RF on outer_train and evaluate outer_test once
aggregate all outer-fold predictions
```